Clasificación Binaria de la Enfermedad de Alzheimer con Redes Neuronales Superficiales y Profundas en Datos Clínicos Tabulares

Johan S.Albarracin-Gomez., Maria P. Carvajal-Martinez.,Diana Y. Barrero Malagon y Santiago García-Rodríguez

***Resumen*— Este proyecto implementa y compara el desempeño de una red neuronal superficial (Shallow Neural Network) y una red neuronal profunda (Deep Neural Network) para la clasificación binaria de la enfermedad de Alzheimer (EA) a partir de datos clínicos estructurados. Se utiliza un conjunto de datos público disponible en Kaggle (2.149 registros), que integra variables demográficas, clínicas, de estilo de vida y evaluaciones cognitivas y funcionales. El flujo metodológico contempla preprocesamiento de valores faltantes, codificación de variables categóricas, escalado de variables numéricas y partición estratificada en entrenamiento, validación y prueba, con el fin de garantizar comparabilidad y evaluación imparcial. La red superficial funciona como línea base, con una sola capa oculta, mientras que la red profunda incorpora múltiples capas y regularización (Dropout y normalización por lotes) para capturar interacciones no lineales de mayor complejidad. Además, se explora un esquema de aprendizaje multitarea en la red profunda, donde se predice simultáneamente el diagnóstico (clasificación) y un puntaje cognitivo continuo (regresión), buscando mejorar la calidad de la representación compartida y la coherencia clínica de las predicciones. El desempeño se cuantificará mediante exactitud, precisión, sensibilidad, F1-score y ROC-AUC para clasificación, y mediante MSE y R^2 para la tarea de regresión. Adicionalmente, se reportará el rendimiento por subgrupos demográficos para identificar posibles disparidades y documentar limitaciones de generalización. Los resultados esperados incluyen un desempeño competitivo con modelos tradicionales reportados para el mismo dataset y una caracterización clara del aporte de la profundidad de la arquitectura y del aprendizaje multitarea en datos tabulares clínicos en salud.**

Palabras Clave—Enfermedad de Alzheimer, Redes Neuronales, Shallow Neural Network, Deep Neural Network, Clasificación Binaria, Datos Tabulares, IA.

I. Introducción

La enfermedad de Alzheimer (EA) es un trastorno neurodegenerativo progresivo que compromete la memoria y otras funciones cognitivas, con impacto directo en la autonomía funcional y la calidad de vida del paciente. A pesar de los avances en biomarcadores y neuroimagen, el diagnóstico temprano sigue siendo un reto clínico debido a la heterogeneidad de los síntomas en etapas iniciales, la disponibilidad limitada de pruebas especializadas y la necesidad de herramientas accesibles que permitan apoyar la toma de decisiones de forma oportuna.

En este contexto, los métodos de inteligencia artificial (IA) han mostrado potencial para apoyar la detección y estratificación del riesgo de EA a partir de diferentes tipos de datos. Una parte importante de la literatura se ha desarrollado sobre bases de neuroimagen como ADNI, que han permitido estandarizar y validar enfoques computacionales basados en MRI para clasificación y pronóstico [1]. Sobre estas fuentes, se han propuesto estrategias de aprendizaje profundo que explotan representaciones jerárquicas a partir de imágenes (p. ej., CNN y variantes), alcanzando rendimientos competitivos en tareas de clasificación clínica [2], [3]. Sin embargo, el uso de neuroimagen puede limitar la escalabilidad en escenarios reales por costo, complejidad logística y requisitos de infraestructura.

En paralelo, ha crecido el interés por modelos basados en datos clínicos estructurados (tabulares) debido a su menor costo y disponibilidad en historia clínica. Estudios recientes usando el dataset público de Kaggle (2,149 registros) reportan resultados altos con aprendizaje automático tradicional y técnicas de balanceo de clases. Biswas *et al.* alcanzaron una exactitud del 91.19% con Random Forest, utilizando SMOTE, selección de características y búsqueda aleatoria de hiper parámetros [4]. Por su parte, Mahamud *et al.* reportaron un 96.35% con un ensamble LightGBM–Random Forest, complementado con selección de características y métodos de explicabilidad tipo SHAP y LIME [5]. Estos trabajos evidencian el potencial de enfoques clásicos en datos tabulares, pero también resaltan retos abiertos relacionados con generalización y transparencia clínica.

Adicionalmente, en aplicaciones médicas de alto impacto es crucial que el modelo no solo sea preciso, sino también interpretable y auditable, de modo que su adopción clínica no dependa de "cajas negras" difíciles de justificar [6]. Bajo esta motivación, el presente proyecto propone diseñar e implementar dos arquitecturas neuronales para clasificación binaria de EA a partir de datos clínicos estructurados: (i) una red neuronal superficial (Shallow NN) como línea base y (ii) una red neuronal profunda (Deep NN). Además, se plantea un esquema de aprendizaje multitarea que permite estudiar el beneficio de compartir representaciones para predecir simultáneamente el diagnóstico y una variable cognitiva continua, con evaluación mediante métricas estándar de clasificación y análisis complementarios de desempeño.

II. Revisión de la literatura

La investigación en IA para el apoyo al diagnóstico de la enfermedad de Alzheimer (EA) se ha desarrollado principalmente en dos líneas: (i) enfoques basados en neuroimagen (MRI, PET, fMRI) y (ii) enfoques basados en datos clínicos estructurados (tabulares), como pruebas cognitivas, variables demográficas, comorbilidades y factores de estilo de vida. En la primera línea, los modelos de aprendizaje profundo han mostrado resultados competitivos debido a su capacidad para aprender representaciones jerárquicas directamente de imágenes médicas, especialmente mediante CNN y arquitecturas 3D; sin embargo, su aplicabilidad clínica puede verse limitada por requerimientos de infraestructura, costos de adquisición y disponibilidad de imágenes de alta calidad, además de retos de generalización entre centros y protocolos [1]–[3].

En la segunda línea, el uso de datos tabulares ha cobrado relevancia por su menor costo y disponibilidad en contextos clínicos rutinarios. En particular, el dataset público de Kaggle propuesto por El Kharoua ha sido utilizado como banco de pruebas para modelos clásicos de aprendizaje automático (ML) y estrategias de balanceo de clases. Biswas et al. implementaron un marco de ML supervisado con selección de características (p. ej., *mutual information*), balanceo mediante SMOTE y optimización de hiper parámetros, evaluando varios clasificadores y obteniendo el mejor desempeño con Random Forest (exactitud de 91.19%) [4].

De forma complementaria, Mahamud et al. propusieron un enfoque *ensemble* que combina LightGBM y Random Forest con *soft voting*, incorporando un pipeline de preprocesamiento (imputación y normalización), manejo del desbalance (por ejemplo, SMOTE y

[1]Todos los integrantes pertenecemos al curso de Redes Neuronales

variantes) y selección de características (Chi-cuadrado y RFE), y reportaron una exactitud de 96.35% en prueba [5]. Un aporte clave de este trabajo es la inclusión de métodos de explicabilidad, orientados a identificar qué variables influyen más en la predicción y a justificar el resultado del modelo de forma comprensible para uso clínico. En sus resultados se destacan medidas ampliamente utilizadas en evaluación cognitiva y funcional, como el Mini-Mental State Examination (MMSE) y las Activities of Daily Living (ADL), lo cual refuerza la trazabilidad clínica del enfoque [5].

Aunque estos resultados sugieren que modelos clásicos y *ensemble* pueden lograr alto desempeño en datos tabulares, la literatura también reconoce limitaciones persistentes: (1) riesgo de dependencia a patrones específicos del dataset y pérdida de generalización en poblaciones externas; (2) sensibilidad al desbalance de clases y a sesgos demográficos; y (3) necesidad de modelos que, además de clasificar, permitan aproximar severidad o deterioro cognitivo mediante variables continuas [6], [7].

En este contexto, el aprendizaje profundo sobre datos tabulares ofrece un marco complementario para modelar relaciones no lineales e interacciones complejas entre variables clínicas y de estilo de vida. Más aún, los esquemas de aprendizaje multitarea permiten compartir representaciones internas para resolver simultáneamente una tarea de clasificación (presencia/ausencia de EA) y una tarea de regresión asociada a deterioro cognitivo (p. ej., predicción de MMSE), con el potencial de mejorar robustez y estabilidad del entrenamiento cuando las tareas están clínicamente relacionadas [8].

En síntesis, el estado del arte respalda el valor de enfoques basados en datos tabulares por su accesibilidad y utilidad clínica, y evidencia que la explicabilidad y la auditoría de sesgos son componentes importantes para su adopción. No obstante, existe espacio para ampliar el análisis hacia: (i) comparación sistemática entre redes neuronales superficiales y profundas en el mismo escenario tabular; (ii) evaluación bajo aprendizaje multitarea para capturar diagnóstico y severidad; y (iii) auditorías básicas de equidad para caracterizar desempeño por subgrupos demográficos.

III. Caso de Estudio

Con el fin de contextualizar la propuesta y establecer una línea base metodológica sobre datos clínicos estructurados, se analizan dos estudios recientes que utilizan el conjunto de datos público de Kaggle propuesto por El Kharoua (2,149 registros).

Estudio 1: ML con optimización y balanceo (Biswas *et al.*)

Biswas *et al.* proponen un marco de aprendizaje automático supervisado para detección de EA sobre datos tabulares, en el que comparan varios clasificadores (incluyendo Random Forest, SVM, Árboles de Decisión, Regresión Logística y KNN) bajo un pipeline que incluye: (i) preprocesamiento y limpieza, (ii) balanceo de clases mediante SMOTE, (iii) selección de características (reportan el uso de *mutual information*), y (iv) optimización de hiper parámetros mediante búsqueda aleatoria. Su mejor resultado se obtiene con Random Forest, alcanzando una exactitud reportada de 91.19% [4].

Este trabajo es valioso porque evidencia que, aun sin arquitecturas profundas, un pipeline sólido de ML puede obtener resultados competitivos y además facilita el análisis de variables influyentes, aspecto clave para la interpretabilidad clínica [4].

Estudio 2: *Ensemble* + explicabilidad (Mahamud *et al.*)

Mahamud *et al.* avanzan hacia un enfoque de combinación de modelos (*ensemble*) integrando LightGBM y Random Forest mediante *soft voting*. Su metodología incorpora un pipeline más completo que considera: (i) imputación de valores faltantes y normalización, (ii) estrategias de manejo del desbalance (incluyendo SMOTE y variantes), y (iii) selección de características mediante Chi-cuadrado y eliminación recursiva (RFE). Bajo este esquema reportan una exactitud de 96.35% en prueba [5].

Un aporte distintivo es la incorporación de métodos de explicabilidad para identificar variables con alta contribución predictiva, destacando medidas cognitivas y funcionales ampliamente usadas en clínica (p. ej., MMSE y ADL), lo cual mejora la trazabilidad clínica del enfoque [5].

Limitaciones identificadas y brecha que aborda esta propuesta

A pesar del alto desempeño reportado, ambos estudios presentan un alcance metodológico limitado frente a los objetivos del presente proyecto: se enfocan en modelos clásicos y *ensemble* sin realizar una comparación sistemática con arquitecturas neuronales (Shallow vs Deep) sobre el mismo escenario tabular, y se restringen principalmente a la clasificación binaria sin incorporar explícitamente un componente de severidad cognitiva continua durante el entrenamiento. Además, aunque incluyen etapas relevantes de preprocesamiento y análisis de variables influyentes, no desarrollan una auditoría formal del desempeño por subgrupos demográficos [4], [5], [7]. En consecuencia, esta propuesta amplía el estado del arte al comparar una red neuronal superficial frente a una profunda y evaluar subgrupos y/o características relevantes para la enfermedad.

IV. Conjunto de Datos

Para el desarrollo del presente proyecto se emplea el Alzheimer's Disease Dataset disponible públicamente en Kaggle, compilado por Rabie El Kharoua [9]. Este conjunto de datos está compuesto por 2,149 registros (pacientes) e incluye variables demográficas, clínicas, de estilo de vida y evaluaciones cognitivas/funcionales, lo que lo hace adecuado para construir modelos predictivos sobre datos clínicos estructurados [5], [9]. La variable objetivo es Diagnosis, codificada como binaria (0 = No Alzheimer, 1 = Alzheimer) [5], [9].

Las características incluyen:

- Variables Demográficas: Edad, género y nivel educativo de los participantes.
- Factores de Estilo de Vida: actividad física, calidad de sueño, hábitos dietéticos y consumo de alcohol/tabaco.
- Historial Médico: Presencia de comorbilidades significativas como hipertensión, diabetes y depresión.
- Medidas Clínicas: variables biomédicas como presión arterial y perfil lipídico (p. ej., colesterol).
- Evaluaciones Cognitivas y Funcionales: Puntuaciones obtenidas en pruebas estandarizadas como el Examen Mínimo del Estado Mental (MMSE) (puntaje cognitivo), Actividades de la Vida Diaria (ADL) (funcionalidad), además de medidas de evaluación funcional.

Previo a la fase de modelado, se implementará un riguroso proceso de preprocesamiento de datos. Este proceso es fundamental para asegurar la calidad y consistencia del *dataset* e incluye, pero no se limita a:

- ➔ Tratamiento de Valores Faltantes: Aplicación de técnicas

adecuadas de imputación o eliminación para gestionar datos incompletos.

- ➔ Normalización de Variables Numéricas: Escalado de características continuas para mitigar el sesgo de variables con rangos de valores amplios.
- ➔ Codificación de Variables Categóricas: Transformación de variables nominales y ordinales a un formato numérico compatible con los algoritmos de *machine learning*.
- ➔ División del Conjunto de Datos: Separación estratégica de los datos en subconjuntos de entrenamiento, validación y prueba, garantizando una evaluación imparcial del rendimiento del modelo.

V. Enfoque Basado en Redes Neuronales

El enfoque se estructura en dos modelos con el objetivo de analizar el efecto de la complejidad arquitectónica al trabajar con datos clínicos estructurados. Ambos modelos se entrenarán bajo el mismo esquema de partición y preprocesamiento descrito previamente, permitiendo una comparación directa del desempeño.

Red neuronal superficial (Shallow NN)

Se implementará una red neuronal superficial como línea base, compuesta por una sola capa oculta y una capa de salida con activación sigmoide para clasificación binaria. Este modelo busca capturar relaciones no lineales simples entre las variables predictoras y la etiqueta Diagnosis, sirviendo como referencia de complejidad baja y entrenamiento estable. Su diseño facilita además el análisis de sensibilidad a hiper parámetros como número de neuronas, función de activación y regularización.

Red neuronal profunda (Deep NN) con aprendizaje multitarea

Se implementará una red neuronal profunda con múltiples capas ocultas para aprender representaciones de mayor nivel a partir de las variables tabulares. Esta arquitectura se plantea bajo un esquema de aprendizaje multitarea, con un bloque de capas compartidas y dos salidas:

1. Salida 1 (clasificación): predicción binaria de Diagnosis mediante una capa densa con activación sigmoide.

2. Salida 2 (regresión): predicción del puntaje cognitivo MMSE mediante una capa densa con activación lineal.

El entrenamiento se realizará minimizando una función de pérdida compuesta que combina la pérdida de clasificación (p. ej., *binary cross-entropy*) y la pérdida de regresión (p. ej., MSE), con ponderaciones ajustables para balancear ambas tareas. Para reducir sobreajuste y mejorar estabilidad se incorporarán técnicas de regularización como Dropout y normalización por lotes (Batch Normalization).

Estrategia de entrenamiento y comparación

Ambos modelos se entrenarán usando el conjunto de entrenamiento, con selección de hiper parámetros basada en el conjunto de validación y evaluación final en el conjunto de prueba. La comparación se centrará en métricas estándar de clasificación (accuracy, precision, recall, F1-score, ROC-AUC) y métricas de regresión para MMSE (MSE y R^2). Adicionalmente, se analizará la contribución de las variables y la consistencia del desempeño por subgrupos demográficos como parte del análisis complementario.

VI. Resultados Esperados

Se espera que la comparación entre una red neuronal superficial (Shallow NN) y una red neuronal profunda (Deep NN) evidencie el impacto de la complejidad arquitectónica en la clasificación binaria de EA sobre datos clínicos estructurados. En particular, se anticipa que la Deep NN alcance un desempeño igual o superior al modelo base, al capturar interacciones no lineales y relaciones complejas entre variables clínicas, demográficas y de estilo de vida.

En términos cuantitativos, se espera obtener métricas de clasificación consistentes y estables en el conjunto de prueba, con un rendimiento global al menos competitivo respecto a lo reportado en la literatura sobre el mismo dataset [4], [5]. Más allá de la exactitud, se priorizará la consistencia de precision, recall, F1-score y ROC-AUC, con énfasis en reducir falsos negativos, dado su impacto en escenarios de detección temprana.

Adicionalmente, el análisis de variables influyentes permitirá identificar predictores con alta contribución al modelo, en línea con hallazgos previos que resaltan la relevancia de medidas cognitivas y funcionales (por ejemplo, MMSE y ADL) junto con variables demográficas y antecedentes médicos [5]. En el caso del enfoque multitarea, se espera que el aprendizaje conjunto mejore la calidad de la representación interna y favorezca la coherencia clínica de las predicciones, aportando simultáneamente una estimación continua asociada al deterioro cognitivo [8].

VII. Evaluación de la Solución

La evaluación se realizará sobre el conjunto de pruebas, manteniendo el conjunto de validación para selección de hiper parámetros y control de sobreajuste. Dado que la propuesta incluye una tarea de clasificación (Diagnosis) y, en el caso multitarea, una tarea adicional de regresión (MMSE), se utilizarán métricas diferenciadas para cada objetivo.

Evaluación para clasificación

El desempeño en clasificación binaria se cuantificará mediante métricas estándar: exactitud (accuracy), precisión (precision), sensibilidad (recall), F1-score y área bajo la curva ROC (ROC-AUC). Adicionalmente, se analizará la matriz de confusión para caracterizar el balance entre falsos positivos y falsos negativos, priorizando la interpretación clínica del error, especialmente en términos de casos no detectados.

Evaluación para regresión (Enfoque Multitarea)

Para la salida continua de MMSE se emplearán métricas de regresión como el Error Cuadrático Medio (MSE) y el coeficiente de determinación (R^2), con el fin de medir tanto la magnitud del error promedio como la capacidad explicativa del modelo sobre la variabilidad del puntaje cognitivo.

Robustez y análisis complementarios

Para fortalecer la confiabilidad de los resultados se reportará el desempeño por particiones (entrenamiento/validación/prueba) y se verificará estabilidad frente a la variación de hiper parámetros y regularización. Finalmente, se incluirá un análisis descriptivo del desempeño por subgrupos demográficos (p. ej., género y rangos de edad), con el fin de identificar posibles diferencias sistemáticas que sugieran sesgos en el comportamiento del modelo.

VIII. Consideraciones Éticas

Privacidad y Confidencialidad: Se utiliza el Alzheimer 's Disease Dataset alojado en Kaggle, el cual es de acceso público y se encuentra debidamente anonimizado mediante identificadores numéricos (Patient ID: 4751 a 6900). Esto garantiza que no sea posible identificar a los pacientes, respetando su derecho a la privacidad y el anonimato.

Adicional a esto, se consideran dos aspectos éticos relevantes. Primero, la privacidad y confidencialidad: los datos serán utilizados exclusivamente con fines académicos, se almacenarán de forma segura y no se intentará ningún proceso de reidentificación. Segundo, el riesgo de sesgo y uso responsable: dado que los modelos predictivos pueden exhibir diferencias de desempeño entre subgrupos poblacionales, se reportará el desempeño por subgrupos demográficos cuando las variables lo permitan, y se discutirán posibles limitaciones de generalización y equidad. De este modo, se evita presentar el modelo como una herramienta clínica definitiva y se enmarca como un sistema de apoyo experimental sujeto a validación adicional antes de cualquier uso en entornos reales [6], [7].

IX. Enlaces Web al Código Fuente y al Video Explicativo

Código fuente

https://github.com/sgarciarod/alzheimers-classification-shallow-vs-deep-nn.git

Video explicativo

https://youtu.be/_vnsacyqcm4

X. Contribución de los miembros del equipo

Miembros del Equipo	Roles	Actividades/Contribuciones
Diana	Lider y Animadora	Supervisión general del cumplimiento de metas, motivación del equipo y revisión final de la coherencia entre objetivos y resultados.
Johan	Coordinador y Secretario	Gestión de la documentación, comunicación directa con el profesor, organización de entregas y administración del repositorio GitHub.
Paula	Experta y Técnica	Diseño de la arquitectura de las redes (superficial y profunda), implementación técnica del aprendizaje multitarea y optimización de hiperparámetros.
Santiago	Investigador y Observador	Revisión de literatura científica, recolección de métricas de equidad y monitoreo crítico de posibles sesgos en los resultados del modelo.

XI. Uso de Herramientas de Inteligencias Artificial

Durante la fase técnica se podrán utilizar herramientas de IA como apoyo puntual, incluyendo Chat GPT, Gemini y Codex, principalmente para tareas operativas y de productividad, por ejemplo: aclaración de conceptos, resolución de errores de implementación en Python, verificación de sintaxis, generación o ajuste de fragmentos de código no sustantivos, sugerencias de hiper parámetros y mejora de la documentación del repositorio. Su uso no sustituirá el trabajo del equipo: la formulación del problema, el diseño metodológico, la selección de métricas, la validación experimental, la interpretación de resultados y las conclusiones serán responsabilidad directa de los integrantes del proyecto. Además, cualquier apoyo relevante se registrará de forma transparente en la documentación (p. ej., en *README* o notas del repositorio) para mantener la trazabilidad del proceso de desarrollo.

XII. Referencias

[1] C. R. Jack Jr., M. A. Bernstein, N. C. Fox, *et al.*, “The Alzheimer’s Disease Neuroimaging Initiative (ADNI): MRI Methods,” *J. Magn. Reson. Imaging*, vol. 27, no. 4, pp. 685–691, 2008, doi: 10.1002/jmri.21049.

[2] H.-I. Suk, S.-W. Lee, and D. Shen, “Hierarchical feature representation and multimodal fusion with deep learning for AD/MCI diagnosis,” *NeuroImage*, vol. 101, pp. 569–582, 2014, doi: 10.1016/j.neuroimage.2014.06.077.

[3] S. Sarraf and G. Tofighi, “Classification of Alzheimer’s Disease using fMRI data and deep learning convolutional neural networks,” *arXiv preprint*, arXiv:1603.08631, 2016.

[4] J. Biswas, M. N. Hasan, M. M. Ul Islam, *et al.*, “Performance-optimized Alzheimer’s detection using machine learning with SMOTE and randomized hyperparameter tuning,” *Discover Artificial Intelligence*, vol. 6, art. no. 95, 2026, doi: 10.1007/s44163-025-00758-z.

[5] E. Mahamud *et al.*, “Enhancing Alzheimer’s disease detection: An explainable machine learning approach with ensemble techniques,” *Intelligence-Based Medicine*, vol. 11, art. no. 100240, 2025, doi: 10.1016/j.ibmed.2025.100240.

[6] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, vol. 1, pp. 206–215, 2019, doi: 10.1038/s42256-019-0048-x.

[7] N. G. Baddam, B. A. Pijani, and S. Bozdag, “A Systematic Fairness Evaluation of Racial Bias in Alzheimer’s Disease Diagnosis Using Machine Learning Models,” *bioRxiv*, 2025, doi: 10.1101/2025.09.30.678854.

(Si luego lo quieres solo con papers “peer-reviewed”, lo reemplazamos por uno publicado en journal; pero por ahora sirve para la auditoría de sesgos en AD.)

[8] J. Liu, X. Tian, *et al*., "Multi-Task Learning for Alzheimer's Disease Diagnosis and Mini-Mental State Examination Score Prediction," *Big Data Mining and Analytics*, 2024, doi: 10.26599/BDMA.2024.9020025.

[9] R. El Kharoua, "Alzheimer's Disease Dataset," Kaggle, 2024.